

비지도 학습

Unsupervised Learning

클러스터링 · 차원 축소

PART 5

클러스터링 Clustering

- 비지도 학습 군집화
- K-Means · 엘보우

PART 5-1

K-평균 군집

K-Means Clustering


- 중심점 기반 반복 군집화

Clustering

- 레이블이 없는 데이터 안에서 패턴과 구조를 발견하는 비지도 학습.
- 목표는 서로 유사한 데이터들을 같은 그룹으로 묶어주는 것.
- 몇 개의 그룹으로 묶을지, 유사도를 어떻게 정의할지를 정해야 한다 (하이퍼파라미터).

비교


Classification vs Clustering



Supervised Learning

(a)

지도 학습 (정답 있음)



Unsupervised Learning

(b)

비지도 학습 (정답 없음)


k-Means 절차

- 1 k — 몇 개의 그룹으로 묶을지 지정한다.
- 2 k개의 임의의 중심점(centroid)을 배치한다 (서로 거리가 최대한 멀어지도록).
- 3 각 데이터를 가장 가까운 중심점으로 할당한다.
- 4 해당 군집의 중심으로 중심점을 이동한다.
- 5 더 이상 중심점의 이동이 없을 때까지 반복한다.


K-MEANS

① 중심점 배치 → ② 가까운 중심점으로 할당


1단계: 임의로 centroid 배치



2단계: 가까운 centroid로 클러스터 할당




③ 각 클러스터 중심점 재계산



K-MEANS


학습 완료 — 중심점 이동 없음



Sum of Square Errors (SSE)


- 적당한 k를 선택하는 방법.
- 관측치와 중심들 사이의 거리.
- 군집들이 얼마나 뭉쳐져 있는지를 나타내는 지표.

$$SSE = \sum_{k=1}^K \sum_{x \in C_k} \text{dist}(x, c_k)^2$$



엘보우 방법 (Elbow Method)

k를 늘려가며 SSE를 측정해, 감소폭이 급격히 줄어드는 '팔꿈치(elbow)' 지점을 최적의 k로 선택한다.



PART 6

차원 축소

Dimensionality Reduction

- 차원의 저주 · 투영 · PCA

Dimension

공간에서 데이터의 위치를 나타내기 위해 필요한 축(Axis)의 수.

2차원

X	Y
184	97
179	83
173	71
188	78

3차원

X	Y	Z
184	97	30
179	83	22
173	71	35
188	78	24



4차원

X	Y	Z	W
184	97	30	127
179	83	22	118
173	71	35	135
188	78	24	122

축이 늘어날수록 차원이 증가한다 → 2차원 · 3차원 · 4차원 ...

Curse of Dimensionality


- 차원이 증가하면 정보의 밀도가 감소한다 (필요한 데이터 수가 지수 함수적으로 증가).
- 정보의 감소로 과적합 문제가 발생하기 쉽다.



해결 방법

- 샘플의 밀도가 충분히 높아질 때까지 훈련 세트의 크기를 키운다 — 단, 데이터 수가 지수적으로 증가해 불가능한 경우가 많다.
- 차원 축소를 한다.
- 특징 선택 (Feature Selection, 변수 선택).
- 특징 추출 (Feature Extraction) — 원본 특징을 조합해 새 특징을 만든다 (PCA, LDA ...).

Projection — 차원 축소의 주요 접근법



PCA — 주성분 분석

머신러닝을 한다면 무조건 알아야 하는 가장 대중적인 선형 차원 축소 알고리즘

원리

데이터가 가장 넓게 퍼져 있는 방향(분산이 큰 방향)을 찾아 새로운 축(주성분)으로 삼습니다. 분산이 크다는 것은 곧 그 방향에 데이터의 핵심 정보가 많이 담겨 있다는 뜻입니다.

특징


- 상관관계가 있는 변수들을 서로 독립적인 새 변수로 변환
- 수학적으로 명확하고 계산 속도가 빠름
- 데이터 압축·전처리에 두루 활용

한 줄 수식

분산을 최대로

$$\mathbf{w}_1 = \arg \max_{\|\mathbf{w}\|=1} \mathbf{w}^\top \Sigma \mathbf{w}$$

$$z = \mathbf{w}_1^\top \mathbf{x} \quad (\Sigma = \text{covariance})$$




단점

데이터가 선형적인 구조일 때만 효과적입니다. (예: 둥글게 꼬여 있는 데이터는 잘 분리하지 못함)

2차원 → 1차원 : 축에 투영해 차원을 줄인다

분산이 가장 큰 주성분 축에 데이터를 "수직으로 내려"(투영) 하나의 축 위 값으로 바꾼다



→ 핵심 정보(분산)는 보존하면서 축 1개로 압축

t-SNE — 고차원을 눈으로 본다


고차원 데이터를 2~3차원으로 줄여 "눈으로 확인"할 때 쓰는 비선형 알고리즘

원리

고차원에서 가까이 있던 점들은 저차원에서도 가깝게, 멀리 있던 점들은 멀리 떨어지도록 확률적으로 배치합니다. 데이터 안의 군집(뭉침) 구조를 기가 막히게 잘 보존합니다.

특징

- 군집·유사성(로컬 구조)을 잘 보존
- MNIST 손글씨·유전자 군집 시각화의 단골
- 데이터 탐색(EDA)에 매우 유용




단점

계산 속도가 매우 느리고 새 데이터에 유연하게 적용하기 어렵습니다. 모델 입력값보다는 시각화·탐색용으로 씁니다.

PCA (Principal Component Analysis)

- 가장 인기있는 차원 축소 알고리즘.
- 분산이 최대로 되는 축을 선택하고, 그 축에 대해 투영한다.
- 첫 번째 축에 직교하고 남은 분산을 최대한 보존하는 두 번째 축을 찾는다.
- 데이터의 분산을 가장 잘 유지하는 축들을 주성분이라 하며, 주성분으로 투영한다.



LDA — 선형 판별 분석


정답(Label)이 있는 지도학습 "분류" 문제에 특화된 차원 축소 기법

원리

클래스(정답) 사이의 거리는 최대한 멀리 떨어뜨리고, 같은 클래스 안의 분산은 최대한 작게 만드는 축을 찾습니다. 즉, 데이터를 잘 "구별"하는 방향을 찾습니다.

특징

- 분류에 유리한 방향으로 차원을 축소
- 축소와 동시에 분류 성능 향상에 직접 기여
- PCA와 닮았지만 "정답"을 활용한다는 점이 다름



단점

정답(Label)이 필요한 지도학습 전용입니다. 라벨이 없는 데이터에는 사용할 수 없습니다.

어떤 걸 골라야 할까?

알고리즘	유형	주 목적	추천 상황
PCA	선형	정보 보존 및 속도 향상	일반적인 전처리, 계산 비용 절감, 데이터 압축
t-SNE	비선형	고차원 데이터 시각화	데이터가 어떻게 뭉쳐있는지 눈으로 확인하고 싶을 때
LDA	선형	분류 성능 극대화	정답(Label)이 명확한 분류 모델을 만들 때

현업 표준 프로토콜 데이터를 받으면 먼저 **PCA**로 차원을 줄여보고, 구조를 직관하기 위해 **t-SNE**로 2차원 플롯을 그려봅니다.

차원 축소, 한 장으로 정리

01

왜?

차원이 많으면 **차원의 저주**·과적합·느린 속도 문제가 생깁니다. 그래서 핵심 정보만 남기고 차원을 줄입니다.

02

무엇으로?

PCA(전처리·압축), **t-SNE**(시각화), **LDA**(분류) — 목적에 맞춰 골라 씁니다.

03

어떻게?

보통 **PCA**로 먼저 줄이고, **t-SNE**로 2차원에 그려 데이터 구조를 눈으로 확인하는 흐름이 표준입니다.

END