

선형 회귀 알고리즘

- 가설 $\rightarrow$ 비용 함수 $\rightarrow$ 최적화
- 최소제곱법 · 경사하강법

독립변수의 개수로 구분

Hours	Scores
2.5	21
3.5	25
5.1	32
6.0	78
7.7	85
9.2	88

단순 선형 회귀

독립변수가 1개인 단순 선형 회귀


다중 선형 회귀

독립변수가 여러 개인 경우 (Multiple Linear Regression)

가설 — 가장 잘 설명하는 직선 찾기

입력과 출력을 선형으로 가정(가설)하고, 무수한 가설 중에서 데이터를 가장 잘 설명하는 직선 하나를 찾는다.

$$\hat{y} = \beta_0 + \beta_1 x$$




가장 잘 설명한다는 의미

가설에서 계산된 값과 실제 값(정답)의 차이(Error)가 최소가 된다는 뜻이다.

$$\hat{y} = -11.32 + 11.67x$$

예시로 학습된 회귀선



RSS 와 MSE

잔차제곱합 (RSS · Residual Sum of Squares)

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

평균 제곱 오차 (MSE · Mean Squared Error)


$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

비용 함수 (Cost Function = Loss Function)

- 정답과 예측의 차이(Loss)를 계산하는 함수.
- 손실: 한 개의 데이터, 비용: 전체 데이터 셋에 대한 값.
- 회귀 알고리즘은 비용 함수가 최소가 되는 파라미터를 찾는 문제다.

목표 — 비용 함수(MSE)를 최소화하는 β_0, β_1 찾기

최소 제곱법 (Ordinary Least Squares, OLS)



비용(RSS)이 최소가 되는 지점에서 기울기(미분값)는 0이 된다. 두 편미분을 0으로 두고 연립방정식을 풀어 β_0 , β_1 을 한 번에 구한다.

$$\frac{\partial}{\partial \beta_0} RSS = 0, \quad \frac{\partial}{\partial \beta_1} RSS = 0$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

PART 3

경사하강법 Gradient Descent

- 비용 함수를 최소화하는 최적화
- 기울기 따라 반복해서 내려가기

경사 하강법 (Gradient Descent)

경사: 기울기, 하강: 내려간다 — 기울기를 따라 반복해서 내려가는 알고리즘. 손실 함수를 최소화하기 위해 반복해서 파라미터를 조정(학습)한다.

비용 함수


$$Cost(\beta) = \frac{1}{2n} \sum_{i=1}^n (y_i - \beta_1 x_i)^2$$

가설

$$\hat{y} = \beta_0 + \beta_1 x$$

손실 함수를 최소화하기 위해 사용되는 최적화 알고리즘이다.

비용 곡면을 따라 최소점으로




파라미터 갱신 규칙

$$\beta_{new} := \beta_{now} - \alpha \frac{\partial}{\partial \beta} Cost$$

α — 학습률 (learning rate). 한 번에 이동하는 보폭을 정한다.

경사 하강법의 학습 절차




- 1 임의의 β 값에서 시작한다.
- 2 그 점에서 경사(Gradient)를 구한다 — 즉 편미분한다.
- 3 기울기의 반대 방향으로, 크기에 비례한 만큼 β 를 빼준다.
- 4 기울기가 0이 되거나 정해진 횟수만큼 반복한다.

$$\beta_{new} := \beta_{now} - \alpha \frac{\partial}{\partial \beta} Cost \quad \alpha: \text{학습률}$$

학습률에 따른 수렴 양상


임의 값에서 시작 → 경사(편미분) 계산 → 기울기 반대 방향으로 이동 → 기울기 0 또는 정해진 횟수까지 반복

학습률이 너무 작다




● 학습률 작다 · 느린 수렴

적절한 학습률



● 적절한 학습률 · 빠른 수렴

학습률이 너무 크다



● 학습률 크다 · 발산·진동

PART 4

다중 회귀 Multiple Regression

- 여러 독립변수로 예측
- 다항 회귀와 비교

다중 회귀 (Multiple Regression)

하나의 종속변수(출력)를 두 개 이상의 독립변수(입력)로 예측하는 모델. 입력과 출력의 관계가 선형(Linear)이다.

$$Y = w_0 + w_1X_1 + w_2X_2 + \cdots + w_nX_n + \epsilon$$

- w_0 : 각 독립변수 X 에 대한 가중치(Weight).
- Y : 출력(종속변수).
- 입력이 증가할 때 출력이 일정한 기울기로 증가/감소한다.



다항 회귀 (Polynomial Regression)

하나의 독립변수(입력)를 다항식 형태로 변환해 종속변수를 예측. 곡선 형태의 비선형 관계를 모델링한다.

$$Y = w_0 + w_1X + w_2X^2 + w_3X^3 + \dots + w_nX^n + \epsilon$$

- 독립변수와 종속변수가 2차식 이상의 관계를 가진다.
- 과적합이 발생하기 쉬우므로 고차항 추가는 신중해야 한다.


모델 형태 비교



구분 정리

구분	다중 회귀 (Multiple)	다항 회귀 (Polynomial)
목적	여러 개의 입력 변수 사용	곡선 형태의 관계 모델링
입력 변수	$X_1, X_2, X_3 \dots$	$X, X^2, X^3 \dots$
관계 형태	선형 (직선)	비선형 (곡선)
수식 구조	$w_1X_1 + w_2X_2$ (각 변수는 1차)	$w_1X + w_2X^2$ (같은 변수의 고차항)

과적합 (Overfitting)



모델이 학습 데이터에 지나치게 맞춰져, 새로운 데이터에 대한 예측이 나빠지는 현상.

$$\beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4$$

고차항이 많을수록 곡선이 과하게 휘어진다

규제 (Regularization)

손실 함수에 패널티 항을 추가해 가중치가 과도하게 커지는 것을 막고 과적합을 방지한다.

L2 정규화

릿지 (Ridge)

$$+ \lambda \sum_j w_j^2 \quad (\text{L2-norm})$$

- 가중치를 0에 가깝게 축소하지만 완전히 0으로 만들지는 않는다.
- 모든 특성이 모델에 남는다.
- 다중공선성이 있을 때 안정성을 높인다.

L1 정규화

라쏘 (Lasso)


$$+ \lambda \sum_j |w_j| \quad (\text{L1-norm})$$

- 중요하지 않은 특성의 가중치를 0으로 만든다.
- 특성 선택(Feature Selection) 효과가 있다.
- 적절한 피처만 회귀에 포함시킨다.

손실 함수에 규제 추가



$$\beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4$$



$$\beta_0 + \beta_1 x + \beta_2 x^2$$

$$\min_{\beta} \sum_{i=1} (y_i - \hat{y}_i)^2 + 5000\beta_3^2 + 5000\beta_4^2$$

OLS · Ridge · Lasso

일반 선형 회귀 (OLS)

예측과 실제 값 사이의 오차 제곱합을 최소화

$$L_{OLS}(\mathbf{w}, b) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\mathbf{w}^\top \mathbf{x}_i + b))^2$$

릿지 회귀 (Ridge)

λ 가 클수록 가중치 패널티가 강해진다 (L2)

$$L_{Ridge}(\mathbf{w}, b) = \sum_{i=1}^n (y_i - (\mathbf{w}^\top \mathbf{x}_i + b))^2 + \lambda \sum_{j=1}^n w_j^2$$


라쏘 회귀 (Lasso)

λ 가 클수록 가중치 패널티가 강해진다 (L1)

$$L_{Lasso}(\mathbf{w}, b) = \sum_{i=1}^n (y_i - (\mathbf{w}^\top \mathbf{x}_i + b))^2 + \lambda \sum_{j=1}^n |w_j|$$

제약 영역의 기하학적 의미

Dimension Reduction of Feature Space with LASSO




PART 3

로지스틱 회귀 Logistic Regression

- 선형 회귀의 한계 → 시그모이드
- 이진 분류 · 손실 함수

가장 잘 설명하는 직선 찾기


회귀란 — 무수한 가설 중에서 데이터를 가장 잘 설명하는 직선 하나를 찾아야 하는 문제다.



종속변수가 범주형이라면?


Y가 범주형([0, 1])이라면, 선형회귀로 해결 가능한가?

Hours	Result
2.5	Fail (0)
3.5	Fail (0)
5.1	Fail (0)
6.0	Pass (1)
7.7	Pass (1)
9.2	Pass (1)



범주형 분류에 부적합


- 출력값의 범위가 $(-\infty, +\infty)$ 범위를 가진다 — 확률(0~1)로 해석할 수 없다.
- 직선은 0과 1로 나뉜 데이터를 잘 설명하지 못한다.




Sigmoid 함수

출력을 0~1 사이의 확률로 변환하는 S자 곡선. 선형식 z 를 확률로 바꿔준다.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



Linear Regression vs Logistic Regression




선형 — 직선으로 회귀

로지스틱 — S자 곡선으로 분류

Logistic Regression


- 입력과 출력의 관계를 시그모이드 함수의 형태로 간주한다.
- 출력값(확률)을 경계값(Threshold)을 기준으로 0과 1로 분류한다 (보통 0.5).
- 계수의 값에 따라 시그모이드의 형태가 결정된다.

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = \beta_0 + \beta_1 x$$



계수에 따른 시그모이드의 형태

$z = \beta_0 + \beta_1 x$ 의 계수가 바뀌면 곡선의 기울기와 위치(결정 경계)가 달라진다.



Odds & Logit — 시그모이드의 유도

- 오즈(Odds) — 사건이 일어날 확률 대 일어나지 않을 확률의 비.
- 로짓(Logit) — 오즈에 로그를 취한 값. 이 로짓을 선형식 z 로 둔다.
- 로짓을 p 에 대해 풀면 시그모이드 함수가 유도된다.

오즈 (Odds)

$$\text{Odds} = \frac{p}{1-p}$$

로짓 (Logit)


$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = z = \beta_0 + \beta_1 x$$

로짓을 선형 회귀로 추정한 뒤, 역변환(시그모이드)하여 확률을 얻는다.

Decision Boundary & Threshold

- 시그모이드 출력(확률)이 Threshold(보통 0.5) 이상이면 1, 미만이면 0으로 분류한다.
- $\sigma(z)=0.5$ 가 되는 지점, 즉 $z=0$ 인 곳이 결정 경계다.
- Threshold를 조정해 분류 기준(민감도/특이도)을 바꿀 수 있다.

$$\hat{y} = 1 \text{ if } \sigma(z) \geq 0.5, \quad \hat{y} = 0 \text{ otherwise}$$



z는 선형회귀로 결정 — 손실함수는?

$z = \beta_0 + \beta_1 x$ 의 계수는 선형회귀처럼 학습으로 결정한다. 그렇다면 분류의 손실함수는 무엇으로 해야 할까?

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = \beta_0 + \beta_1 x$$


손실함수는 ?

Mean Squared Error 를 쓰면?


시그모이드에 MSE를 적용하면 비용 함수가 비볼록(Non-Convex)이 되어, 경사 하강법이 지역 최소에 빠질 수 있다.

$$Cost = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

MSE + 시그모이드 → 비볼록(Non-Convex)



Cross Entropy → 볼록(Convex)



Cost Function

- 정답과 예측값의 차이에 비례해 값을 반환한다.
- 정답과 가까우면 작은 값을, 정답과 멀면 큰 값을 반환하면 된다.
- 학습이란 비용 함수를 최소로 만드는 파라미터를 찾아내는 것이다.

사이킷런 LogisticRegression — 이름은 회귀, 정체는 분류기

이름에 'Regression'이 있지만 실제로는 확률을 추정해 클래스를 나누는 분류기(classifier)다.

① 선형 결합

$$z = X\mathbf{w} + b$$

입력 X 에 가중치 w 와 절편 b 를 곱해 더한 점수 z 를 만든다.

② 시그모이드 → 확률

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}$$

z 를 0~1 사이 확률로 변환한다.
0.5를 기준으로 클래스를 결정.

③ 정규화된 손실 최소화

$$\min_{\mathbf{w}, b} \mathcal{L}(\mathbf{w}, b) + \lambda R(\mathbf{w})$$

로그 손실 + 규제항을 가장 작게 만드는 w, b 를 찾는다.

핵심

경사하강법을 직접 구현하지 않는다. 검증된 외부 최적화 라이브러리인 **solver**에 최적화를 위임한다.

→ 우리는 데이터와 옵션만 정하면 되고, 가중치를 찾는 수치 최적화는 라이브러리가 안정적으로 처리한다.


사이킷런 LogisticRegression — Solver

Solver	특징
<code>lbfgs</code>	기본값. 메모리 효율적, 뉴턴 방법(Newton's method) 계열.
<code>liblinear</code>	작은 데이터셋에 적합. L1·L2 규제 지원.
<code>sag / saga</code>	대용량 데이터에 적합. saga는 L1 규제 지원.
<code>newton-cg</code>	2차 도함수(Hessian) 사용. 다중 분류에 적합.

이진 분류 vs 다중 분류 — 경계선이 몇 개 필요한가


클래스가 2개면 직선 하나로 충분하지만, 3개 이상이면 여러 개의 경계가 필요하다.

이진 분류 (Binary)



직선 1개로 두 클래스를 나눈다.

다중 분류 (Multi-class)



클래스마다 경계가 필요 → 분류기 여러 개.

아이디어 — 이진 분류기를 여러 개 합친다 (OvR)

클래스 K개를 한 번에 못 나누면, '이 클래스인가? 아닌가?'를 묻는 분류기를 K개 만든다.



A 인가? 아닌가?

이 클래스에 속할 확률을
0~1로 출력하는 이진 분류기



B 인가? 아닌가?

이 클래스에 속할 확률을
0~1로 출력하는 이진 분류기



C 인가? 아닌가?

이 클래스에 속할 확률을
0~1로 출력하는 이진 분류기

각 분류기가 내놓은 확률 중 가장 높은 클래스를 최종 정답으로 고른다. (One-vs-Rest)

이진 분류기 3개를 나란히 — 각자 확률을 출력

각 분류기는 입력 X 에 자기 가중치 W 를 곱해 z 를 만들고, 시그모이드로 0~1 확률을 낸다.



가장 높은 확률(0.8) → 클래스 B 로 예측한다.

선형 회귀

Linear Regression

독립변수와 종속변수의 선형 관계를 가정하고, 데이터를 가장 잘 설명하는 직선을 찾는다

PART 1

선형 회귀란?

- 선형 관계 가정 (가설)
- 데이터를 가장 잘 설명하는 직선 찾기

선형 회귀 (Linear Regression)

독립변수와 종속변수를 선형적인 관계로 가정(가설)하고, 데이터를 가장 잘 나타내는 선형식(함수)을 찾는다.

$$\hat{y} = \beta_0 x_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3$$

여러 독립변수 X 와 계수 β 로 출력 $\hat{y}$ 를 선형 결합한다

단순 선형 회귀 (Simple Linear Regression)

독립변수가 1개인 선형회귀.


$$\hat{y} = \beta_0 + \beta_1 x$$

β_0 — 절편(bias), β_1 — 기울기(weight)

Hours	Scores
2.5	21
3.5	25
5.1	32
6.0	78
7.7	85
9.2	88

Hours → Scores 예시 데이터

단순 vs 다중 선형 회귀



단순 — 독립변수 1개

다중 — 독립변수 2개 이상

선형 · 다중 · 다항

SIMPLE LINEAR

단순 선형 회귀

독립변수 1개로 직선 관계를 모델링

MULTIPLE

다중 회귀

독립변수 여러 개로 예측

POLYNOMIAL

다항 회귀

고차항으로 곡선(비선형) 관계 모델링

END