


Machine Learning Overview

데이터에서 규칙을 스스로 학습해, 새로운 입력에 대한 결과를 예측하는 기술

AI · 머신러닝 · 딥러닝 · 생성형 AI



- **AI**

인간의 지능을 컴퓨터로 모방하는 기술 또는 시스템

- **Machine Learning**

데이터에서 잠재된 패턴과 규칙을 발견하도록 훈련하는 기술

- **Deep Learning**

인간의 신경망을 모방해 여러 층으로 깊게 쌓아 학습하는 기술

- **Generative AI**

학습한 패턴을 바탕으로 규칙을 따르는 새로운 데이터를 만드는 모델

PART 1

머신러닝이란?

- 데이터에서 규칙을 학습
- 함수 근사로 미래를 예측

정의

머신러닝이란,

"명시적인 프로그래밍 없이 컴퓨터가
학습하는 능력을 갖추게 하는 연구 분야"

— Arthur Samuel, 1959



머신러닝의 두 축

01

Learn from Data

데이터(과거)에 숨겨진 정보와 규칙을 기계가 스스로 습득한다.

02

Function Approximation

학습 결과로 새로운 입력(미래)에 대한 결과를 예측한다.

데이터(과거)에 숨겨진 규칙을 학습하고, 그 결과로 새로운 입력(미래)에 대한 결과를 예측하는 기술

Function Approximation

입력	출력
2	5
3	7
4	9
5	11


입력과 출력의 관계(규칙)를 찾는다

함수 근사는 입력 x 와 출력 y 사이의 관계 $f(x)$ 를 데이터로부터 추정하는 과정이다.

발견한 규칙 $y = 2x + 1$

목적 — 처음 보는 데이터에 대해서도 적합한 출력을 얻기 위함

입력을 출력으로 잇는 함수 $f(x)$



머신러닝을 적용할 수 있는 경우

1

데이터를 구할 수 있다

학습에 필요한 충분한 데이터가 확보되어야 한다.

2

관심 있는 규칙이 존재한다

데이터 안에 우리가 찾고자 하는 패턴이 있다고 판단될 때.

3

전통적 방법으로 풀기 어렵다

명시적 프로그래밍으로는 해결책이 없는 복잡한 문제.

PART 2

데이터

- 데이터 형식과 구조
- 변수와 데이터의 종류

정형 · 반정형 · 비정형



STRUCTURED

정형 데이터

표 형식으로 정리된 데이터

데이터베이스 · 스프레드시트 · CSV



SEMI-STRUCTURED

반정형 데이터

구조 정보를 포함한 데이터

XML · HTML · JSON



UNSTRUCTURED

비정형 데이터

형식이 정해지지 않은 데이터

이미지 · 동영상 · 음성 · 텍스트

변수 · 특성 · 피처 (Feature)

brand	model	year	mileage	fuel	price
Audi	A1	2017	15735	Petrol	12500
Audi	A6	2016	36203	Diesel	16500
Audi	A1	2016	29946	Petrol	11000
Audi	A4	2017	25952	Diesel	16800

← 관측치 (Sample, Instance)

↑ 변수 (각 관측치의 특성, n차원)

관측치 — 샘플(Sample), 인스턴스(Instance) 변수 — 각 관측치의 특성 (n 차원 데이터)

변수 구분

독립변수(X) 와 종속변수(Y)

brand	model	year	mileage	fuel	price
Audi	A1	2017	15735	Petrol	12500
Audi	A6	2016	36203	Diesel	16500
Audi	A1	2016	29946	Petrol	11000
Audi	A4	2017	25952	Diesel	16800

X

독립변수

입력 (Input)

- 특성 (Feature)
- 피처 (Feature)

Y


종속변수

출력 (Output)

- 타깃값 (Target)
- 라벨 (Label) · 클래스 (Class)

수치형 · 범주형

	검사회수	BMI	혈액형	고혈압	혈압
1	3	24.2	A	Y	121
2	2	20.0	O	N	112
3	1	21.7	A	N	107
4	2	25.4	B	Y	132




PART 3

머신러닝의 학습 방법

- 지도 / 비지도 / 강화 학습
- 사례 기반 vs 모델 기반

지도 · 비지도 · 강화 학습



Supervised Learning

머신러닝 알고리즘을 학습시킬 때 타깃값(레이블, 정답)을 사용한다. 학습 데이터에는 최종적으로 얻고자 하는 결과값이 포함되어 있어야 한다.

타깃값

brand	model	year	mileage	fuel	price
Audi	A1	2017	15735	Petrol	12500
Audi	A6	2016	36203	Diesel	16500
Audi	A1	2016	29946	Petrol	11000
Audi	A4	2017	25952	Diesel	16800

↑ price 열이 정답(타깃)으로 함께 주어진다

Unsupervised Learning

머신러닝 알고리즘을 학습시킬 때 타깃값(레이블, 정답)을 사용하지 않는다. 학습 데이터에 타깃값이 포함되어 있지 않거나, 구할 수 없는 경우다.

Glucose	BloodPressure	SkinThickness	Insulin	BMI	Age
148	72	35	0	33.6	50
85	66	29	0	26.6	31
183	64	0	0	23.3	32
89	66	23	94	28.1	21

정답 열이 존재하지 않는다 — 데이터의 숨은 구조만으로 학습한다

사례 기반 vs 모델 기반 학습

INSTANCE-BASED

사례 기반 학습

기존 데이터를 기억해 두고(학습), 새로운 데이터는 기존 데이터와의 유사도를 측정해 결정한다.

MODEL-BASED

모델 기반 학습

기존 데이터에서 규칙(모델, 함수)을 찾고, 그 규칙을 이용해 예측한다.


두 가지 과제



분류

Classification

범주(Class)를 예측한다



회귀

Regression

연속형 수치를 예측한다

회귀와 분류 — 타깃값의 차이

회귀 (Regression)

키	몸무게	체지방%	혈압
184	97	23	127
179	83	20	118
173	71	15	113
188	78	25	135

연속형 숫자 → 수치 예측 (회귀)


분류 (Classification)

키	몸무게	체지방%	고혈압
184	97	23	Y
179	83	20	N
173	71	15	N
188	78	25	Y

범주형 → 범주 예측 (분류)

이진 분류(합격/불합격) · 다중 분류(혈액형) — 레이블, 클래스

직관적 비교




두 가지 과제



군집

Clustering

비슷한 데이터끼리 묶는다




차원 축소

Dimension Reduction

특성 수를 줄여 압축한다


Clustering

타깃 변수가 없다. 특성이 비슷한 데이터끼리 묶는다.



Dimension Reduction

많은 특성(차원)을 핵심 정보를 보존하며 더 적은 수의 특성으로 압축한다.



PART 4

학습 데이터 준비

- 인코딩 · 특성 스케일링
- 이상치 · 결측치 · 데이터 불균형

Train · Validation · Test

모델을 학습·선택·평가하기 위해 데이터를 세 갈래로 나눈다.

TRAIN

학습

모델을 학습시키는 데이터

VALIDATION

검증


모델 선택·튜닝에 사용

TEST

테스트

최종 성능 평가, 학습에 미사용

학습 vs 검증 vs 테스트




테스트 데이터는 학습에 사용되지 않는다. 검증 데이터는 모델 선택과 튜닝에 쓰인다.

X (특성) 와 y (타겟) 분리

	특성 (X)	타겟 (y)
학습 · Train	X_train	y_train
검증 · Validation	X_val	y_val
테스트 · Test	X_test	y_test

Cross-Validation (K-Fold, k=5)

학습 세트를 여러 서브셋으로 나누고, 각 조합으로 훈련·검증한 뒤 평균 성능으로 모델을 선택한다.



평균값
사용

학습이 끝나면 선택된 최종 모델을 전체 학습 세트로 다시 학습시킨다.

Encoding

문자열로 표현된 범주형 데이터를 숫자로 변환하는 전처리

범주형 → 숫자

혈액형·고혈압처럼 문자로 된 범주형 값은 알고리즘이 처리할 수 있도록 숫자로 바뀌어야 한다.

혈압	검사회수	혈액형	고혈압
121	3	A	Y
112	2	O	N
107	1	A	N
132	2	B	Y

강조된 두 열(혈액형·고혈압)이 인코딩 대상인 범주형 변수다

Label Encoding

혈압	회수	혈액형	고혈압		혈압	회수	혈액형	고혈압
121	3	A	Y	→	121	3	0	1
112	2	O	N		112	2	2	0
107	1	A	N		107	1	0	0
132	2	B	Y		132	2	1	1

혈액형 A:0, B:1, O:2, AB:3 고혈압 N:0, Y:1

One-Hot Encoding

- 가까운 두 값이 더 비슷하다고 오판하는 오류를 막는다.
- 큰 숫자를 더 중요하다고 오판하는 오류를 막는다.

혈액형		A	B	O	AB
A		1	0	0	0
O	→	0	0	1	0
A		1	0	0	0
B		0	1	0	0
AB		0	0	0	1

회귀 알고리즘이라면 다중공선성을 막기 위해 한 개 열을 삭제하기도 한다.

Feature Scaling

변수의 값 범위를 일정한 수준으로 맞추는 작업


왜 필요한가

나이	연봉	경력
25	39343	1.2
31	46205	2.0
38	37731	2.2
41	43525	2.9

연봉은 수만, 경력은 한 자릿수 — 범위 차이가 크면 학습이 한쪽에 치우친다

- 값을 조정하는 과정이므로 수치형 변수에만 적용한다.
- 특성마다 범위가 다르면 모델이 제대로 학습되지 않을 수 있다.
- KNN · SVM · Clustering · Neural Network 에 특히 중요하다.


스케일링 전과 후



Min-Max Normalization

- 최대값 1, 최소값 0, 나머지는 0~1 사이로 변환한다.
- 이상치(Outlier)에 많은 영향을 받는다.

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$



Z-Score Normalization

- 평균 0, 분산 1이 되도록 변환한다.
- 이상치(Outlier)에 영향을 덜 받는다.
- 데이터가 정규분포를 따르도록 한다 (NN에 효과적).

$$z = \frac{x - \mu}{\sigma}$$

μ = 평균(Mean)

σ = 표준편차

중앙값과 IQR 사용

- 평균·분산 대신 중앙값(median)과 IQR을 사용한다.
- 사분위값으로 변환해 이상치 영향을 최소화한다.

$$z = \frac{x - Q_2}{Q_3 - Q_1} = \frac{x - Q_2}{IQR(x)}$$

PART 5


이상치와 결측치

- Outlier 탐지 — IQR · Z-Score
- 결측치(Missing Value) 처리

이상치

Outlier


분류



회귀



정규분포와 표준편차



정규분포에서 데이터가 평균으로부터 얼마나 떨어져 있는지로 이상치를 판단한다.

$\mu \pm 1\sigma$

68%


$\mu \pm 2\sigma$

95%

$\mu \pm 3\sigma$

99.7%

Z-Score 방법




$$z = \frac{x - \mu}{\sigma}$$

Z-Score가 +3보다 크거나 -3보다 작은 데이터를 이상치로 처리한다. 거의 모든 값(99.7%)이 평균 $\pm 3\sigma$ 범위에 존재한다.

IQR 방법

$$(Q_1 - 1.5 \text{ IQR}) < x < (Q_3 + 1.5 \text{ IQR})$$

이 범위를 벗어나는 값을 이상치로 처리한다



Missing Value

- 비어 있거나 판단할 수 없는 문자로 표현된 값.
- 결측치를 포함한 행을 버리거나, 특별한 값(0·평균·중간값·최대·최소)으로 채운다.

키	몸무게	체지방	혈압
184	97	25	127
179	83	—	118
173	—	15	113
188	78	15	135

‘—’로 표시된 셀이 결측치다

Imbalanced Data

클래스별 샘플 수가 크게 차이는 데이터

오버 샘플링 vs 언더 샘플링

- 오버 샘플링 — 소수 클래스의 샘플을 늘린다 (SMOTE, ADASYN 등).
- 언더 샘플링 — 다수 클래스의 샘플을 줄인다.



PART 6

모델 학습

- 과대적합 vs 과소적합
- 하이퍼파라미터 · 성능 평가

좋은 모델

학습이 잘 된 모델이란

01

현재 데이터를 잘 설명한다

학습 데이터의 패턴을 정확히 포착한다.


02

새로운 데이터를 잘 예측한다


미래 데이터에 대해서도 예측을 잘 한다 (일반화, Generalization).

Over-Fitting vs Under-Fitting — 회귀

모델을 지나치게 복잡하게 학습하면 학습 데이터 성능은 높지만, 새로운 데이터에 대한 예측은 정확하지 않다.



분류



Hyper-Parameter

학습 전에 사람이 직접 설정하는 모델의 설정값

두 파라미터의 차이

HYPER-PARAMETER

하이퍼파라미터

학습 전에 사람이 직접 설정하는 값

학습률 · 배치 크기 · 에폭(epoch)

MODEL PARAMETER


모델 파라미터

학습으로 자동 결정되는 모델 내부 값

가중치(weight) · 편향(bias)

최적의 조합 찾기

Grid Search와 Random Search로 최적의 하이퍼파라미터를 탐색한다.



Evaluation

분류 모델 평가

Confusion Matrix · Accuracy · ROC

회귀 모델 평가

MSE · RMSE · MAE · R^2

Classification Metrics

정답과 예측을 비교해 분류 성능을 측정한다

Confusion Matrix

		Predicted	
		NEGATIVE	POSITIVE
Actual	NEG	TN True Negative	FP False Positive
	POS	FN False Negative	TP True Positive

TP · FP · TN · FN

TP

True Positive

양성으로 예측 → 정답도 양성

FP

False Positive

양성으로 예측 → 정답은 음성

TN

True Negative

음성으로 예측 → 정답도 음성

FN

False Negative

음성으로 예측 → 정답은 양성

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$ 민감도 == Recall 재현율
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$ 특이도
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$ 정확도

정밀도
(Positive Predictive Value)

Accuracy

- 전체 중에서 정답으로 맞춘 비율.
- 전체 메일에서 스팸/정상을 옳게 분류한 비율.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

예시 (45+30) / (45+20+5+30) = **75%**

Precision (Positive Predictive Value)

- 양성이라고 판정한 것 중 실제로 양성인 비율.
- 스팸이라고 판정한 메일 중 실제 스팸의 비율.

$$Precision = \frac{TP}{TP + FP}$$

예시 45 / (45+5) = **90%**

Recall · Sensitivity · TPR

- 실제 양성 중에서 양성이라고 예측한 비율.
- 실제 스팸 메일 중 스팸이라고 예측한 비율.

$$Recall = \frac{TP}{TP + FN}$$

예시 45 / (45+20) = **69.23%**


F1 Score

- 정밀도(Precision)와 재현율(Recall)을 하나의 숫자로 표현.
- 두 지표의 조화 평균 — 둘이 비슷할수록 F1도 높아진다.
- 0~1 사이 값, 높을수록 분류기 성능이 좋다.

$$F_1 = 2 \cdot \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \cdot \frac{Precision \times Recall}{Precision + Recall}$$

Receiver Operating Characteristic

- Threshold를 변화시키며 TPR(민감도)과 FPR(1-특이도)을 그래프로 나타낸다.
- 곡선이 좌상단에 붙을수록 더 좋은 분류기다.



AUC

Area Under Curve

ROC 곡선 아래쪽 면적을 0~1 사이로 표현한 값. 1에 가까울수록 우수한 분류기다.

0.9 ~ 1.0

Excellent

0.8 ~ 0.9


Good

0.7 ~ 0.8

Fair

< 0.7

Poor




Regression Metrics

실제값과 예측값의 오차로 회귀 성능을 측정한다

오차를 최소화한다

- 오차(Error) — 실젯값과 예측값의 차이.
- 회귀는 오차가 최소가 되도록 모델(선의 식)을 최적화한다.

$$Error = y_i - \hat{y}_i$$



MSE · RMSE · MAE

Mean Squared Error

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Root Mean Squared Error

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Mean Absolute Error

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

R² (R Square)

- 독립변수(X)가 종속변수(Y)를 어느 정도 설명하는지 나타내는 지표.
- R²=0.3이면 독립변수가 종속변수의 30%를 설명한다.
- 1에 가까울수록 잘 설명한다.


$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

① 회귀 적용 전 — 평균선 기준 오차

회귀 적용 전, y 값의 평균과 데이터 사이의 오차(SST)를 계산한다. 평균을 예측선으로 가정한 경우다.

제공한 잔차들의 합 = **41.1879**

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$




② 회귀 적용 후 — 모델 기준 오차

최소제곱 회귀로 얻은 모델을 기준으로 잔차(SSR)를 계산한다.

잔차 제곱합 **41.1879 → 13.7627**

$$SSR = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



③ 결과 — R² 계산

전 (SST)

41.1879



후 (SSR)

13.7627

R²

66.59%

$$\frac{41.1879 - 13.7627}{41.1879} = \frac{27.4252}{41.1879} = 66.59\%$$

END